

Experimentelle Analyse von Algorithmen für fair-k-center mit Ausreißern

Bachelorarbeit

von

Carsten Krollmann

aus

Pirmasens

vorgelegt bei

Lehrstuhl für Algorithmen und Datenstrukturen

Prof. Dr. Melanie Schmidt

Heinrich-Heine-Universität Düsseldorf

Februar 2013

Betreuer:

Dr. Daniel Schmidt

Zusammenfassung

Hier beschreibe ich nun auf einer Seite, welches Problem ich betrachte, wie ich es gelöst habe und was die Hauptergebnisse meiner Arbeit sind.

Laut Prüfungsordnung muss es eine Zusammenfassung geben, die nicht länger als eine Seite ist.

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation	1
1.2	Aufbau der Arbeit	1
2	Aufbereiten der Daten	2
2.1	Ursprungsdaten	2
2.1.1	Literatur	3
2.2	Cleaning-Pipeline	3
3	Algorithmen	4
3.1	Gonzalez	4
3.2	Fairletts	4
3.3	Fair-Clustering mit Ausreißern	5
4	Experimente	6
4.1	Graphen	6
5	Auswertung	7
5.1	Beschreibung der Bilder	7
5.2	Güte der Algorithmen	7
	Literatur	8

Kapitel 1

Einleitung

1.1 Motivation

Das hier ist die Einleitung. Hier sollte darauf eingegangen werden, was die Motivation der Arbeit ist.

1.2 Aufbau der Arbeit

Gehe kurz darauf an, was den Leser in den nächsten Abschnitten erwartet. Die Gliederung kann vorab mit der betreuenden Person abgesprochen werden.

Kapitel 2

Aufbereiten der Daten

Um vergleichbare Werte zu erhalten, habe ich mich an einem Paper orientiert, welches ebenfalls probiert hat Fair-k-Center zu lösen [Chi+18]. Für die Vergleichbarkeit

2.1 Ursprungsdaten

In dem Chierichetti-Paper [Chi+18] wurden 3 Unterschiedliche Datensätze verwendet. Darunter:

- Daten eines US-Zensus [BK96]
- Daten von Telefongesprächen einer Bank [MRC12]
- Einen Diabetes-Datensatz, wobei der im Paper [Chi+18] verlinkte Datensatz [Kah] nicht der Richtige Datensatz sein kann (Er enthält andere Felder als die genannten). Nachforschungen haben herausgestellt, dass sie in Wirklichkeit einen anderen Diabetes-Datensatz [Clo+14] benutzt haben

2.1.1 Literatur

Alle wissenschaftliche Literatur, die man verwendet, wird im Literatur-Verzeichnis aufgeführt. Dieses wird automatisch von Bibtex erzeugt. Dazu muss zunächst ein Eintrag in der Bibliographie-Datenbank im bib-Ordner angelegt werden. Man findet z. B. mit Google Scholar für wissenschaftliche Veröffentlichungen fertige Zitationsangaben im Bibtex-Format.

Noch ein wenig Mehr Zitieren:

1. Chierichetti-Paper [Chi+18]
2. Zensusdaten [BK96]
3. Bankdaten [MRC12]
4. Diabetes (Falsch) [Kah]
5. Diabetes (Richtig) [Clo+14]
6. BA von Irina [Fas23]
7. Vorlesungsskript Clustering [Sch23]

2.2 Cleaning-Pipeline

Was habe ich gemacht um an meine Batches/Subsamples zu kommen?

Kapitel 3

Algorithmen

Welche Algorithmen habe ich implementiert/genutzt und was habe ich mit ihnen gemacht.
Vielleicht technische Feinheiten wie geben die Algorithmen etwas zurück

3.1 Gonzalez

- Wie funktioniert Gonzalez grob
- vielleicht, was ist die Rückgabe (Zentren, Knoten mit Clusterzugehörigkeit, maxradius)

3.2 Fairletts

- How to Flussnetzwerk
- Fairletts verbinden
- Art der Rückgabe

3.3 Fair-Clustering mit Ausreißern

- was bringen die Fairlets
- wie werden sie zu Zentren zugewiesen

Kapitel 4

Experimente

- Was genau hab ich jetzt berechnet
- Welche Daten habe ich explizit verwendet (kurz)
- Diagramm der Testing-Pipeline
- Umgebung (vielleicht technische Daten)
- Graphen aus Python

4.1 Graphen




Abbildung 4.1: Kosten für Gonzalez bis zu 30 Cluster

Kapitel 5

Auswertung

Was habe ich aus den Experimenten gelernt

5.1 Beschreibung der Bilder

5.2 Güte der Algorithmen

Konvergieren die Algorithmen gut? Wie groß ist der Kostenunterschied? Wie groß ist der Unterschied zwischen den Datensätzen?

Literatur

- [BK96] Barry Becker und Ronny Kohavi. *Adult*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5XW20>. 1996.
- [Chi+18] Flavio Chierichetti u. a. *Fair Clustering Through Fairlets*. 2018. arXiv: 1802.05733 [cs.LG].
- [Clo+14] John Clore u. a. *Diabetes 130-US hospitals for years 1999-2008*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5230J>. 2014.
- [Fas23] Irina Fast. „Fair k-Center Clustering mit Ausreißern“. Masterarbeit. Düsseldorf, NRW, Germany: Heinrich Heine University, Dez. 2023.
- [Kah] Michael Kahn. *Diabetes*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5230J>.
- [MRC12] S. Moro, P. Rita und P. Cortez. *Bank Marketing*. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5K306>. 2012.
- [Sch23] Melanie Schmidt. „Kombinatorische Algorithmen für Clusteringprobleme - Vorlesungsskript“. 2023.

Ehrenwörtliche Erklärung

Hiermit versichere ich, die vorliegende Bachelorarbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt zu haben. Alle Stellen, die aus den Quellen entnommen wurden, sind als solche kenntlich gemacht worden. Diese Arbeit hat in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen.

Düsseldorf, 29. Februar 2013

Carsten Krollmann



Hier die Hülle
mit der CD/DVD einkleben

Diese CD enthält:

- eine *pdf*-Version der vorliegenden Bachelorarbeit
- die $\text{\LaTeX}$ - und Grafik-Quelldateien der vorliegenden Bachelorarbeit samt aller verwendeten Skripte
- **[anpassen]** die Quelldateien der im Rahmen der Bachelorarbeit erstellten Software XYZ
- **[anpassen]** den zur Auswertung verwendeten Datensatz
- die Websites der verwendeten Internetquellen